AI Master Challenge

001 – Diagnóstico de Churn – Dados / Analytics

Por Lucas Oriani Carreira

001 – Diagnóstico de Churn – Dados / Analytics

Analise / diagnóstico

Contexto: A **RavenStack**, plataforma SaaS, com ~500 contas, opera com modelo de assinatura.
Nos últimos meses as preocupações com relação à retenção de clientes aumentou.

O CEO quer respostas:

"Estamos perdendo clientes e não sei por quê.
*Os **números mostram que o churn subiu**,*

*mas o time de CS diz que a **satisfação está ok**.*
*O time de produto diz que o **uso da plataforma cresceu**.*

Algo não bate.

Preciso de alguém que olhe pra isso com olhos frescos e me diga o que está acontecendo de verdade."

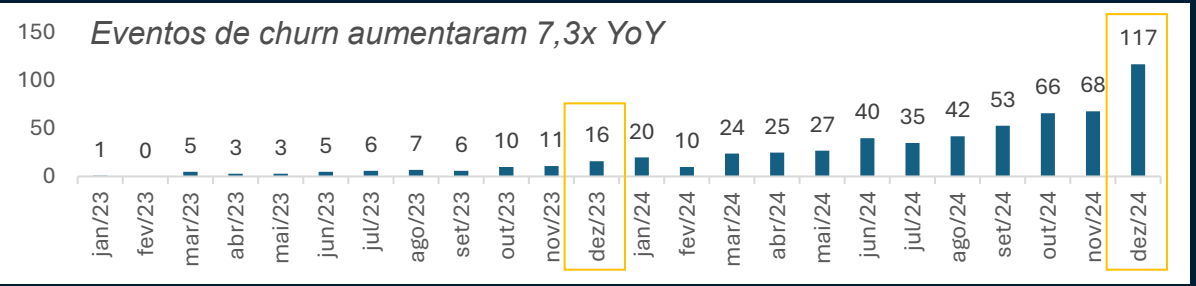

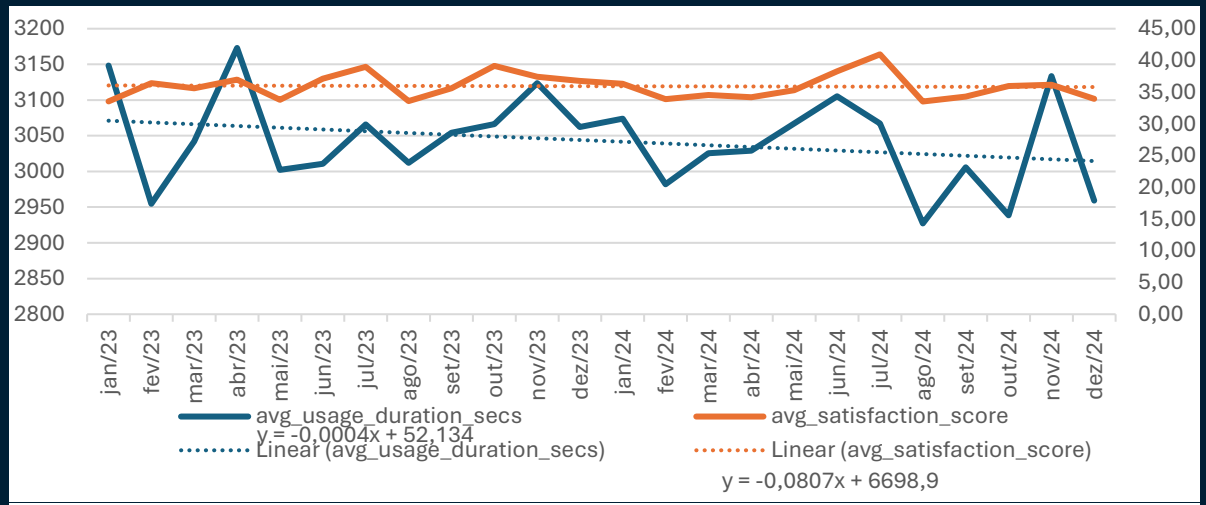

- *Afirmação de CS é parcialmente verdade, satisfação segue "estável" (ok)*
  Mas apresenta tendência de queda (e mais acentuada nos últimos meses)
- *Já Produto, não condiz, cresceu pontualmente em nov/24, mas segue a baixo da média histórica*

001 – Diagnóstico de Churn – Dados / Analytics

Método / Abordagem – Data Wrangling

Resumo	Tabela															
nivel da conta/ cadastro do cliente	ravenstack_accounts.csv	account_id	account_name	industry	country	signup_date	referral_source	plan_tier	seats	is_trial	churn_flag					
quando e pq o cliente saiu	ravenstack_churn_events.csv	account_id	churn_event_id	churn_date	reason_code	refund_amount_usd	preceding_upgrade_flag	preceding_downgrade_flag	is_reactivation	feedback_text						
comportamento dentro do produto	ravenstack_feature_usage.csv	usage_id	subscription_id	usage_date	feature_name	usage_count	usage_duration_secs	error_count	is_beta_feature							
receita com comportamento	ravenstack_subscriptions.csv	account_id	subscription_id	start_date	end_date	plan_tier	seats	mrr_amount	arr_amount	is_trial	upgrade_flag	downgrade_flag	churn_flag	billing_frequency	auto_renew_flag	
fricção e experiencia	ravenstack_support_tickets.csv	account_id	ticket_id	submitted_at	closed_at	resolution_time_hours	priority	rst_response_time_minute	satisfaction_score	escalation_flag						

key
string
data
boollean
integer
float

Tabelas abaixo são por conta, ou seja, 1 linha para cada cliente

- **Ravenstack_accounts**
- **Ravenstack_subscriptions**

As tabelas abaixo são de interação, ou seja, cada linha é um evento e o cliente pode ter mais mais de um evento

- **Ravenstack_churn_events**
- **Ravenstack_feature_usage**
- **Ravenstack_support_tickets**

Para seguirmos com a analise, foi agregada as 5 tabelas em uma visão por conta

Isso visa facilitar analise e modelagem, além de limpar/normalizar a base.

001 – Diagnóstico de Churn – Dados / Analytics

G4

Método / Abordagem – Analise Master Table

- A base combina da 5 tabelas avalia três dimensões principais:
  - **Comportamento** (uso do produto)
  - **Experiência** (suporte)
  - **Valor** (monetização)

Essa estrutura permite identificar não apenas *o "churn"*, mas **por que ocorre**.

🚨 **Antes de seguir com a análise, foi encontrada Inconsistência crítica de churn ao consolidar as bases na Master Table**

Há clientes marcados com a flag churn na base de accounts e que **não necessariamente**, tem evento de churn na base de churn_events

Linha	account_churn_flag	churned	cont
1	0	1	277
2	1	1	75
3	0	0	113
4	1	0	35

- ⛔ Cliente não tem flag churn, mas tem evento de churn registrado
- ✅ Cliente tem flag churn e tem evento de churn registrado
- ✅ Cliente não tem flag churn e não tem evento de churn registrado
- ⛔ Cliente tem flag churn, mas não tem evento de churn registrado

Hipótese

- Erro na base
- Churn é status ou evento?
- Conflito de definição de churn
  - Churn financeiro x churn operacional

Tratativa

- Se for isso, inviabiliza o estudo
- Vale uma revisão com stakeholders
- Companhia precisa definir conceituo core, pode haver visões secundárias para departamentos específicos, desde que não conflita com plano tático

DEFINIÇÃO: para seguir, foi considerado o churn da tabela churn_events, a informação é mais detalhada (quebra por data) e viabiliza outras analises

001 – Diagnóstico de Churn – Dados / Analytics

Método / Abordagem – Modelo Supervisionado [boosted_tree_classifier]

- Melhor que um estudo, é uma abordagem via **modelo Descritivo**
  - *Futuramente evolua para um preditivo e prescritivo realtime, mas o foco do case foi analisar o passado*

Evaluate Modelo

precision	recall	accuracy	f1_score	log_loss	roc_auc
0.711538461538...	0.986666666666...	0.704761904761...	0.826815642458...	0.632344411439...	0.427714285714...

O modelo apresenta **alta sensibilidade** (recall ~99%), sendo eficaz na identificação de contas em risco.
No entanto, o baixo ROC AUC (~0.43) indica
limitação na capacidade de discriminar globalmente entre churn e não churn.
O churn não segue um padrão linear ou globalmente separável, **mas sim padrões específicos e contextuais**

Peso por variavel

feature	importance_weight	importance_gain	importance_cover
industry	1	1.93642366	119.45475
error_rate_per_usage	5	1.79951973	110.7369388600...
ticket_count	5	1.4604865434	96.4799347
avg_resolution_time_hours	4	1.8433645650000001	83.205861325
escalation_rate	1	0.970461726	133.0
usage_per_seat	2	0.8505369285	13.9453988
has_usage	0	0.0	0.0
has_tickets	0	0.0	0.0

Variáveis que mais explicam o churn, elas tem grande representatividade no comportamento do churn

- **Error_rate_per_usage (**Erros por uso)
  - Fricção técnica (driver crítico de churn)
- **Ticket_Count (**Nº tickets)
  - Fricção operacional
- **Avg_resolution_time_hours (**Tempo de resolução)
  - Eficiência do suporte

Variáveis importante, havia a preocupação se o problema estaria localizado em algum segmento

- **Industry (segmento)**
  - Apresentou pouca importância para o churn, no model

Conclusão: é um problema ligado resolução de tickets, suporte não consegue “desatritar” o cliente, em todos os segmentos (industry)

001 – Diagnóstico de Churn – Dados / Analytics

Resultados: O que está causando o churn?

Eventos de churn

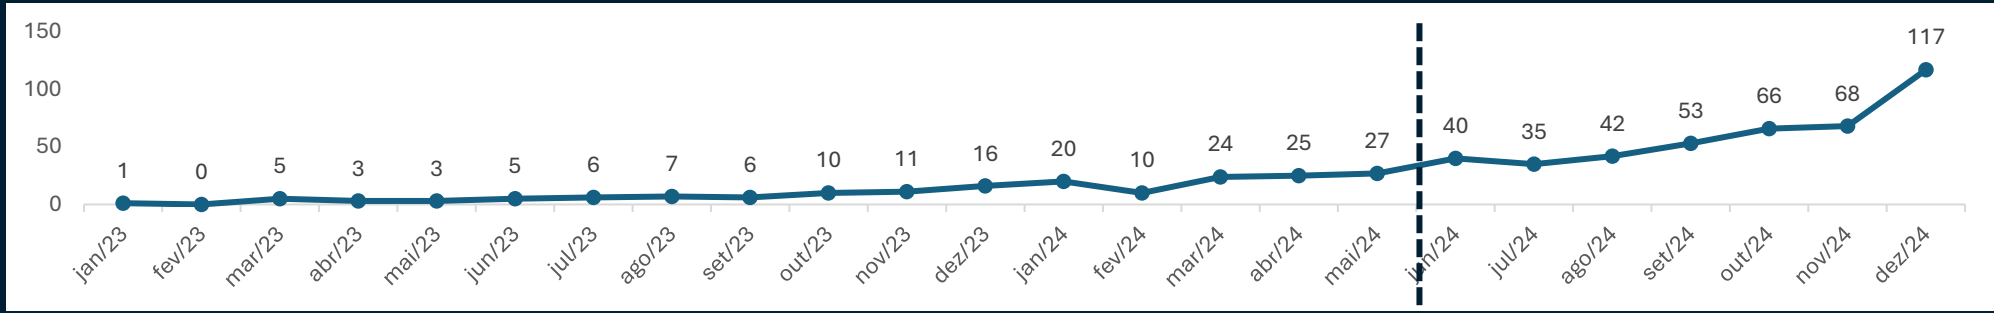

Relação

- **Quantidade de tickets**
- **Tempo médio em horas, para resolver tickets**
- **Tempo total de horas resolvendo tickets**

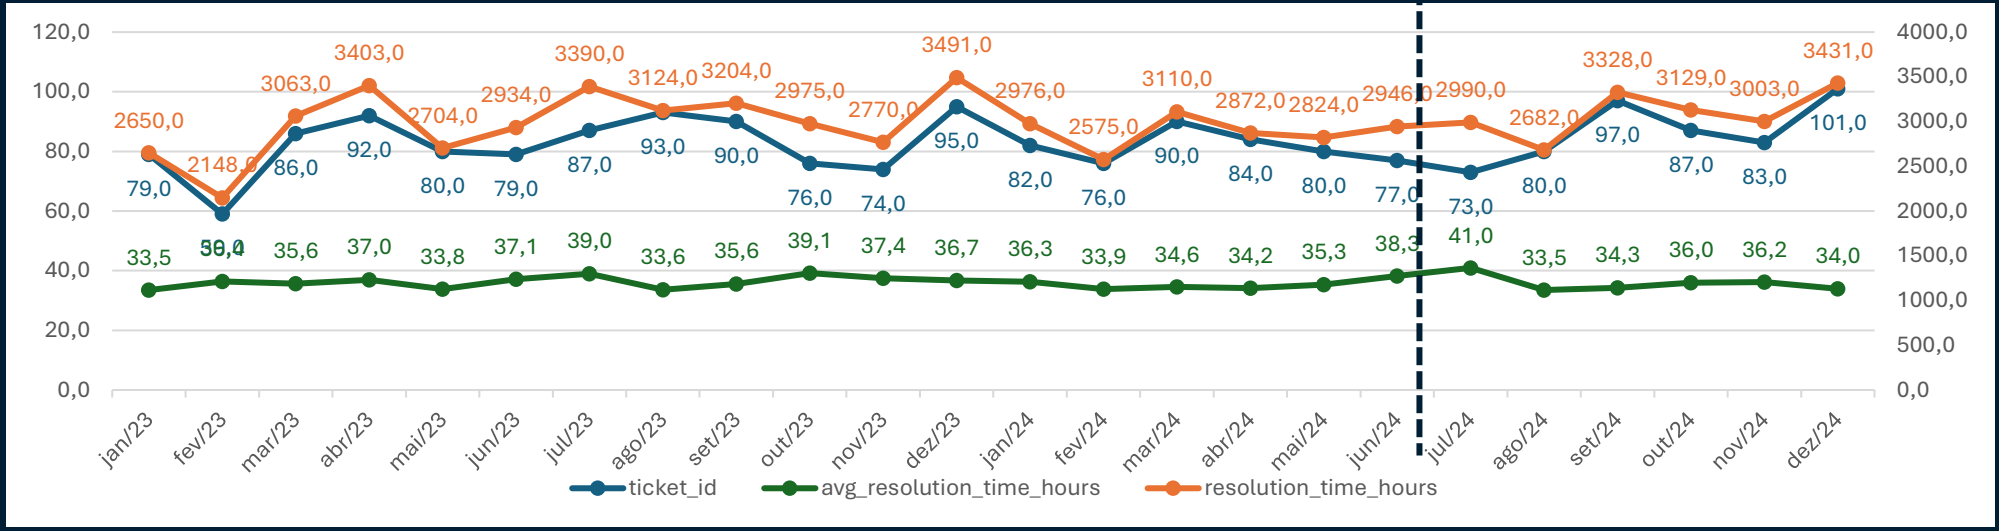

Tempo médio de resolução segue estável, mas devido ao **aumento no volume de tickets** á um acumulo de horas em tratativa, que correlaciona com o churn.

001 – Diagnóstico de Churn – Dados / Analytics

Resultados: Quais segmentos estão mais em risco?

	clientes	flag_churn	%	event_churnn	%
FinTech	112	25	22%	76	68%
HealthTech	96	21	22%	64	67%
Cybersecurity	100	16	16%	72	72%
DevTools	113	35	31%	83	73%
EdTech	79	13	16%	57	72%

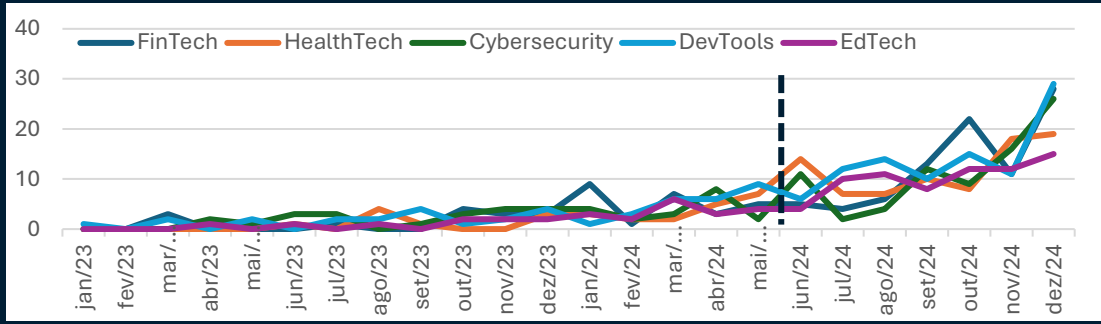

Se fossemos olhar churn pela tabela de accounts, segmento de Devtools apresenta churn maior. Olhando por eventos de churn, não há um segmento que se destaca,
O preocupante é que todos os segmentos tem aumento de eventos de churn a partir do meio de 2024

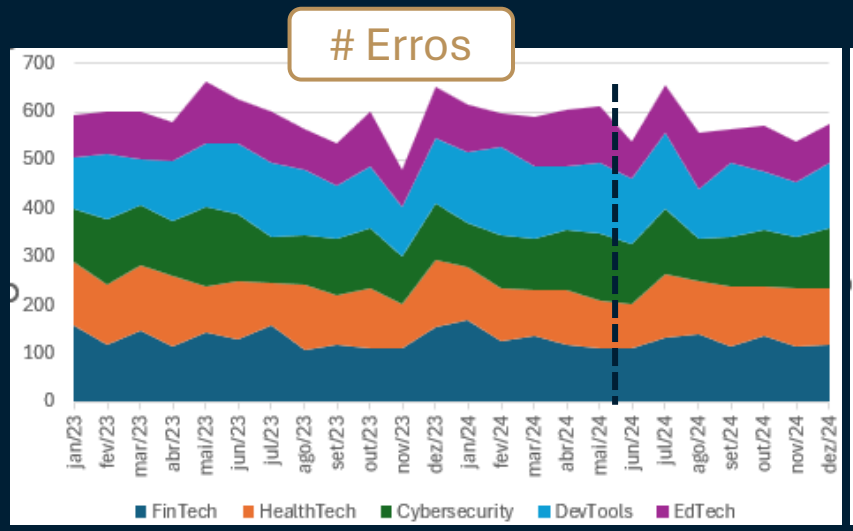

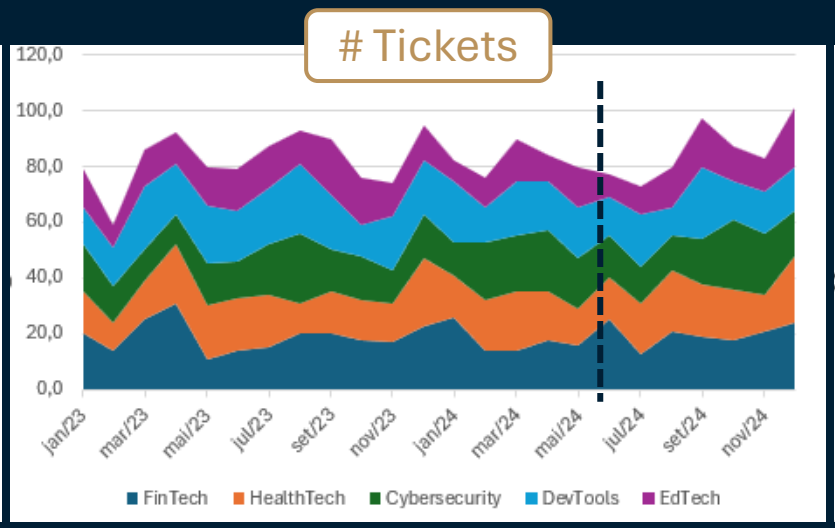

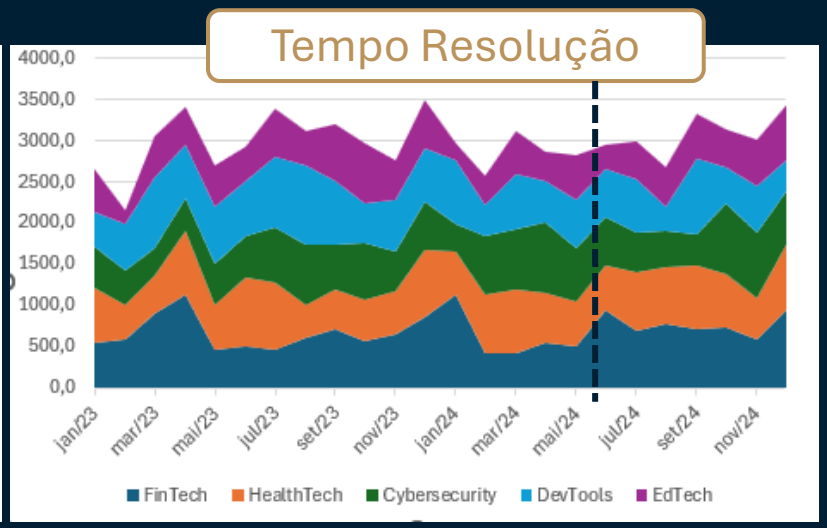

Quantidade de erros não teve aumento expressivo, o que aumentou foi o volume de tickets (em todos os segmentos) e consequentemente o tempo médio de resolução
O que indica uma dificuldade de operacionalização do atendimento ao aumento de tickets

001 – Diagnóstico de Churn – Dados / Analytics

Plano de Ação: O que a empresa deveria fazer?

Ações de Curto Prazo

- **Error_rate_per_usage (Erros por uso)**
Diminuir erros técnico com atendimento ativo e preditivo

- **Ticket_Count (Nº tickets)**
Sanar causa raiz de abertura de tickets

- **Avg_resolution_time_hours** (Tempo de resolução)
Reorganizar e redimensionar o time de suporte para diminuir tempo de resolução
Focar em clientes mais rentáveis, criar atendimento dedicado

- **Criar uma matriz RACCI**
  - Plano de comunicação em caso de incidente

- **Dashboards e alertas** realtime

- Adicionar churn e métricas correlatas ao **plano de metas** (PLR)

- **Rever estrutura organizacional e gestão**
  - O problema evoluiu ao longo de 2024
  - Falta de urgência / ownership

Ações de Médio Prazo

- **Criar célula de pós-retenção**
  - Atendimento próximo durante quarentena

- **Canais de atendimento com o score de churn do cliente que estão atendendo**
  - Descriminado por pontos de atrito

- **Criar célula de retenção pró-ativa**
  - Se o score do cliente subir, alarma e o time ativamente atende e “desatrita” o cliente

- **Backlog de produto e CS alimentados via modelo**
  - No roadmap dessas áreas deve ter prioridade correção de incidentes ligados ao churn

- **Agente supervisor de qualidade**
  - Analisa os tickets abertos
  - Cruza com transcrições
  - Avalia se o atendimento foi eficaz e resolutivo

Ações de Longo Prazo

- **Modelo de correção de erros on demand**

- **Copiloto de atendimento**
  - Usando dados do agente supervisor de qualidade
  - Gera recomendação de atendimento para novos tickets similares
  - Expor na tela do atendente em tempo de atendimento
    - Ou até dar autonomia de um agente aplicar correção

Obrigado G4